

Réalisé par Mr. SAID EL YAZAMI

Project :

Prédiction du résultat d'analyse médicale d'un patient hospitalisé

Objectifs et consistance du projet ML ::

- ✓ Traduire un problème métier en tâche ML supervisée régression ou classification. (dans notre cas dans mon projet, le type du ML c'est la classification) .
- ✓ Conduire une analyse exploratoire rigoureuse et communiquer les insights clés.
- ✓ Construire un pipeline ML reproductible et robuste.
- ✓ Sélectionner, évaluer et optimiser le modèle le plus adapté à la problématique.
- ✓ Déployer une application de prédiction interactive sur Streamlit Cloud.

A propos de Datasets :

- Source du data : healthcare_dataset.csv (Kaggle)
- Type ML : Classification
- Description : Dataset synthétique simulant des dossiers hospitaliers de patients, incluant des informations démographiques, des données médicales et des données administratives.
- 55 500 dossiers de patients hospitalisés.
- Target : Résultat du bilan médical du patient : Normal, Abnormal, ou Conclusive (3 classes)

Table des Matières

- 1- Présentation.
- 2- La source du Dataset et la nature des données.
- 3- Distribution de la variable cible.
- 4- Analyse Exploratoire des Données (EDA).
- 5- La transformation appliquées et Pré-processing aux données.
- 6- Algorithme de Machine Learning utilisé.
- 7- Déploiement.
- 8- La sauvegarde des fichiers du projet.
- 9- Commandes pour lancer le projet.

■ 1- Présentation :

Ce rapport présente la démarche complète de mise en œuvre du Projet du Module 5 «Machine Learning» du Master Data Engineering MSDE7 de l'École Hassania des Travaux Publics (EHTP).

L'objectif central est la prédiction automatique du résultat d'un bilan médical (Normal, Abnormal, Inconclusive) à partir de données hospitalières, une problématique de classification multiclasse résolue par apprentissage supervisé.

Dimension ML	Définition
Type de tâche	Classification multiclasse (3 classes)
Variable cible (y)	Test Results : Normal Abnormal Inconclusive
Variables explicatives (X)	9 features sélectionnées après preprocessing
Métrique principale	Accuracy (précision globale) + F1-score macro
Paradigme	Apprentissage supervisé batch

■ 2- La source du Dataset et la nature des données :

Le dataset utilisé est **healthcare_dataset.csv**, un jeu de données synthétique représentatif des environnements hospitaliers modernes. Il contient **55 500** enregistrements et **15 variables** couvrant les dimensions démographiques, cliniques, administratives et financières des patients.

Variable	Type	Description
Name	Texte	Nom du patient (supprimée)
Age	Entier	Age du patient (0 – 100 ans)
Gender	Catégorielle	Sexe : Male / Female
Blood Type	Catégorielle	Groupe sanguin (8 catégories)
Medical Condition	Catégorielle	Pathologie principale (6 catégories)
Date of Admission	Date	Date d'entrée (transformée en durée)
Discharge Date	Date	Date de sortie (transformée)
Doctor	Texte	Nom du médecin (supprimée)
Hospital	Texte	Hôpital (supprimée)
Insurance Provider	Catégorielle	Assureur (5 catégories)
Billing Amount	Continu	Montant facturé en USD \$
Room Number	Entier	Numéro de chambre (supprimée)
Admission Type	Catégorielle	Type d'admission (3 catégories)
Medication	Catégorielle	Médicament prescrit (5 catégories)
Test Results	Catégorielle	CIBLE : Normal / Abnormal / Inconclusive

■ 3- Distribution de la variable cible :

La variable cible présente une distribution quasi-uniforme entre les trois classes, ce qui est favorable pour l'apprentissage et évite les problèmes de déséquilibre de classes (class imbalance).

Classe	Effectif	Proportion
Abnormal	18 627	33,6 %
Normal	18 517	33,4 %
Inconclusive	18 356	33,1 %
TOTAL	55 500	100 %

■ 4- Analyse Exploratoire des Données (EDA) :

L'analyse exploratoire a été conduite en plusieurs étapes, conformément aux meilleures pratiques de la science des données :

- Vérification de la structure du dataset (df.info(), df.shape).
 - Détection des valeurs manquantes (Aucune valeur nulle constatée).
 - Analyse de la distribution de chaque variable (histogrammes, boxplots).
 - Visualisation de la variable cible (countplot par classe).
 - Analyse des corrélations entre variables numériques et la cible.
-

■ 5- La transformation appliquées et Pré-processing aux données :

Nous avons effectué trois opérations majeures :

- **Calcul de séjour** : Création de Days_Hospitalized à partir des dates d'admission et de sortie.
 - **Nettoyage** : Suppression des identifiants personnels
(Suppression des colonnes non informatives comme : Name, Doctor, Hospital, Room Number).
 - **Standardisation et normalisation** : Standardisation des variables numériques avec StandardScaler pour équilibrer les échelles numériques.
-

■ 6- Algorithme de Machine Learning utilisé :

Nous avons choisi le Random Forest Classifier. Cet algorithme d'ensemble construit 100 arbres de décision différents et fusionne leurs résultats pour une prédiction plus stable et précise.

L'évaluation de modèle repose sur la **Matrice de Confusion** et le **Classification Report**. Ces outils permettent de voir non seulement la précision globale, mais aussi la capacité du modèle à distinguer chaque classe (Normal vs Anormal).

■ 7- Déploiement :

L'application interactive (**app.py**) a été développée avec Streamlit charge le modèle sauvegardé en mémoire. Elle permet à l'utilisateur de saisir les informations d'un patient via l'interface, et le script calcule instantanément les probabilités de chaque résultat d'analyse de son test médical via des graphiques interactifs, accompagnée d'un niveau de confiance (probabilité).

■ 8- La sauvegarde des fichiers du projet :

Le projet est sérialisé avec **Joblib** dans le dossier **models**. Cela inclut le modèle, le **scaler** et les **encodeurs**. Le dossier est totalement autonome et prêt pour la mise en production.

■ 9- Commandes pour lancer le projet

Pour lancer l'application : `streamlit run app.py`

Pour réentraîner le modèle : `python train_model.py`